

英语背诵与学习软件 (cat paw)

端侧离线 AI 英语背诵工具 · 2026 上海开源软件应用创新大赛 · 开源 AI 工具赛道

项目负责人: 康容恺 (上海师范大学) | 代码许可: Apache-2.0 | 文档日期: 2026-09-26

一句话: 把课文或试卷 (打字、拍照、传 PDF 都行) 丢进去, 本机大模型自动提炼**生词·词组·作文金句·搭配·语法**, 按**考纲 × CEFR × 学生历史掌握**三层过滤生成背诵清单, 再用**默写 + SM-2 间隔复习**闭环到长期记忆。 **全程离线运行, 学习数据不出机器。**

一、项目背景与痛点

1.1 评价的指挥棒已经转向"用语言解决问题"

课程层面。《义务教育英语课程标准 (2022 年版)》把课程目标定为**语言能力、文化意识、思维品质、学习能力**四方面核心素养, 课程内容以**主题为引领**, 由主题、语篇、语言知识、文化知识、语言技能、学习策略六要素构成; 教育部在发布说明中对外语课程给出的实施要求是——"通过语言学习活动, 帮助学生在**体验中学习、在实践中运用、在迁移中创新**". 《普通高中英语课程标准 (2017 年版 2020 年修订)》更直接把课程目标从"综合语言运用能力"转向**学科核心素养**, 其"语言能力"的官方定义是"**在社会情境中**, 以听、说、读、看、写等方式理解和表达意义的能力".

评价层面。教育部考试中心研制的《中国高考评价体系》确立"四翼"考查要求——基础性、综合性、**应用性**、创新性, 其中**应用性明确强调"学以致用"**; 该体系并首创性地把"**情境**"确立为**考查载体**, 即"让学生在真实的背景下.....运用必备知识和关键能力去解决实际问题". 评价理念也从"知识立意、能力立意"转向"**价值引领、素养导向、能力为重、知识为基**".

题型层面 (最直观的证据)。教育部考试中心在《2020 年全国高考命题评析》中说明, 英语科"**推出读后续写题型, 创造性地将'阅读'与'写作'深度结合**, 深入考查学生的综合语言运用能力、思维能力和学习能力", 并"**减少完形填空题量和分值, 取消短文改错题, 增加阅读理解和写作分值**".

地方层面。上海市教委公布的高考英语改革自 2025 届春考起实施: "**听力理解**"从**笔试中分离, 并入"听说测试"一起上机考**——笔试由 140 分调整为 115 分, 听说测试由 10 分调整为 35 分; 官方对这轮改革的定性是"**对学生英语实际应用能力的考察**", 并称"**强调语言'听'和'说'的比例更高, 哑巴英语已经成为过去式**".

这意味着: 初高中英语考察的重心, 已经不是"认不认识这个词、记不记得这条释义", 而是**能不能在真实的语境里理解它、并在需要的时候把它用出来**。

1.2 主流学习工具的两个缺口

市面上主流英语学习 App 的产品逻辑高度一致: **给出词表 → 卡片式记忆 → 间隔重复提醒 → 游戏化维持打卡**。它以"记住更多单词"为优化目标, 但在应试与真实运用中留下了两个致命缺口。

缺口一: 只注重单词记忆, 不注重运用。学生被训练的是"词—义"的连线, 而考试考察的是"语境 → 意义 → 表达"的完整链条。于是常见的一幕是: 词表背了很多遍, 一到阅读里认不出它的具体义项、一到写作里用不出来。一词多义与熟词僻义 (screen 名词是"屏幕"、动词是"筛查") 尤其吃亏——背过这个词, 却在句子里读不懂。

缺口二：缺乏定制化的语境。主流工具提供的是**通用词表**，而不是与"你正在面对的材料""你自己的生活"绑定的语境。而学生真正要对付的语境恰恰是很具体的：

语境来源	学生的真实处境	通用词表 App
考题中的语境	这张卷子里的这个词，考的是哪个义项？常和哪个搭配一起考？	只给最常见的一两条释义
日常生活中的语境	想表达"我昨天遇到的事"这类属于我自己的内容，该用哪个词、怎么搭？	没有对应入口
学生自己经历的语境	我感兴趣的话题（体育、游戏、科技）里出现的表达	不可能覆盖

1.3 学校已经在做"提炼"，但它的覆盖是有边界的

值得注意的是：**帮助学生提炼这件事，学校其实一直在做**——几乎所有学校都会采用"英语提炼"的形式辅助学生记单词：老师**针对卷子与考题，提炼出其中的单词、词组与考点**。这是非常有效的做法，但它的边界也很清楚，而这条边界恰恰暴露了学生自主学习时最大的空缺：

	学校的提炼	学生自己刷题 / 做阅读时
谁做提炼	老师（专业、有经验）	没有人 ——学生只能自己查词、凭感觉判断该背什么
面向谁	面向大众 ：要照顾班里不同层次的同学，取舍偏保守、偏共性	本应 面向我自己 ：只看我没掌握的、我需要的
覆盖材料	老师选定并讲解的材料	学生手上任何材料 （自己买的卷子、感兴趣的外刊）

一句话概括这个空缺：**老师的提炼是"一对多"的，而学生自主学习时需要的是"一对一"的——但一对一的成本，老师付不起。**

1.4 我们的选择：把"提炼"交到学生自己手里

本软件要做的不是又一个背单词 App，而是把**"提炼"这一步从老师手里，变成学生自己就能随时完成的工具**：

- **输入即提炼**：粘贴文本、拍照、传 PDF/Word——用学生**手上任何材料**（课内课文、自己的卷子、感兴趣的外刊），由本机大模型结合语境提炼出这篇材料里该学的生词、词组、作文金句、搭配与语法
- **个性化分层**：按"考纲词书 × CEFR 等级 × 个人历史掌握"三层过滤，并识别**熟词僻义**；定位是**学生的自助自检**——只看自己没掌握的，效率优先
- **闭环到记忆**：候选自评 → 中英双向默写（含原文例句挖空）→ SM-2 间隔复习 + 掌握三分 + 每日自测
- **不止于提炼**：软件还包含**聊天（AI 语伴纠错、作文批改）与阅读模块**，除听力外基本覆盖英语学习的各个环节，适配现代学生的使用习惯
- **用兴趣换内驱力**：英语学习中大量内容本身枯燥，而学生可以**挑选自己感兴趣的题材**作为阅读材料——同一套提炼与记忆机制，读的是你喜欢的东西，学习内驱力自然不同

1.5 选择全本地模型：一个被忽视的学校诉求

学校对**题目、试卷、作文**这类资源是有隐私顾虑的——这正是许多优质资源“不敢上云”的原因。本软件把模型与数据全部放在本机：**不发起任何上传请求**，学习数据只存在本地；在**机房不联网、校园网受限**的场景下也能正常使用。这不是技术上的保守，而是针对真实使用场景的设计选择。

1.6 作者的视角

我自己走完了高中三年的英语学习。回头看，真正吃掉时间、也最让我无力的环节其实不是“背”，而是**没人替我做提炼**。


在学校里，老师会针对卷子和考题提炼单词、词组与考点——这个方法很有效，但它是**面向全班**的，要照顾不同层次的同学；而当我课后自己刷题、自己做阅读的时候，就**没有人再为我做这件事了**：一篇陌生材料摆在面前，哪些词是我真正该攻的、这个词在这句里是哪个义项、它和哪个搭配一起考，全得自己判断，效率很低。

所以我结合 AI 做了这款软件，想解决的正是这个空缺：**让每个学生都能给自己做“一对一”的提炼**——把手上任何材料丢进去，由本机模型结合语境提炼、按自己的水平分层，再自检、默写、按计划复习。**它不需要替代老师，而是补上“老师不在场时”的那一段。**

我也特意让它不只做提炼：**聊天与阅读**也做了进来，除听力外的环节都能覆盖；并允许学生**自选感兴趣的题材**当阅读材料——因为英语学习最难的不是方法，而是**愿意持续下去**。

二、技术架构

2.1 总览



2.2 关键设计决策

决策	理由
端侧模型而非云 API	目标场景（学生日常学习）里隐私与"随时可用"是硬需求；Gemma 4 已改为 Apache-2.0，商业与再分发无阻碍
llama.cpp 而非 Ollama	可直接挂 mmproj 做多模态（拍照识别），且能塞进单文件夹一体化分发；Ollama 保留为可选回退路径
Node 零依赖后端	不需要 npm install，clone 下来就能跑——把"陌生人 5 分钟能用"作为一等目标
词书过滤用规则而非模型	"这个词是不是考纲词"必须确定性、可复现；模型只负责语言理解，判断交给规则层与词书数据
学习记忆放浏览器	学生数据零落盘、零上传；代价是清浏览器数据即重置（已在文档中明示）

2.3 三条输入链路

1. **文本**：直接粘贴，长文（>2200 字符）自动切块合并
2. **照片**：RapidOCR 快路径（印刷体 ~1-2 秒）→ 质量不足自动切内置视觉模型（复杂版面 / 手写）→ 双保险
3. **文档**：PDF（文本型直接抽字 / 扫描版逐页渲染识别）、Word、txt；识别文字回填输入框，可编辑确认后提炼

2.4 可移植性（面向"陌生人能跑"）

后端对 Python 采取**降级优先**的探测链：内嵌 macOS Python → 内嵌 runtime\python → ES_PYTHON 环境变量 → 本机候选 → python3 / python；全部找不到时，照片 OCR 与文档解析自动降级，**粘贴文本与视觉模**

型链路不受影响。模型与引擎不随仓库分发，由 `tools/` 下脚本按 **sha256 逐字节校验**从上游获取；无模型时软件仍可启动（界面、词书、默写、记忆层全部可用）。

三、应用场景

场景	用法与价值
学生自学（主场景）	课后把课文 / 试卷阅读拍照进软件 → 20 秒内得到按自己水平筛过的背诵清单 → 当天默写 + 次日进入 SM-2 复习排程。把"整理"这一环从二三十分钟压到几十秒。
教师布置与讲评	老师把自己选的阅读材料一键生成清单（可复制为文本发群），学生端导入同一篇材料即可对齐；当前版本的班级功能尚未实现（见第五节）。
无网 / 弱网环境	校园网受限、机房不联网、家庭宽带不稳的场景完全可用；模型与词书都在本机。
隐私敏感场景	学生作文、试卷、成绩相关信息全程不出机器——这是很多学校愿意采用本地工具而非云服务的关键理由。
面向开发者的复用	"清单 → 默写 → SM-2 排程"这套记忆内核与词书构建流水线（ <code>scripts/</code> ）都是独立可复用的：其他教育类开源项目可直接接入自己的词表。

四、创新点（对比式说明）

4.1 端侧推理，而非调用云端 API

已有方案：同类背单词 App 与 AI 学习工具普遍把文本上传至云端模型。

不足：隐私外泄风险、断网不可用、按量计费、校园网络受限时不可用。

本项目：Gemma 4 E2B (Apache-2.0) 经 llama.cpp 在本机 GPU 推理，**实测 8-20 秒/篇**（RTX 5060 Laptop 8GB，约 67 tok/s）；断网可用、零调用费用、数据不出机器。

4.2 三层过滤 + 熟词僻义，而非"模型吐一张词表"

已有方案：让模型直接输出"本课生词"，结果依赖模型对"学生水平"的猜测。

不足：不可解释、不可复现、无法对应各地考纲差异、漏掉"认识但新义项没学过"的词。

本项目：

- ① **考纲层**——全文词与主词书做机械扫描比对，确定性地标注"考纲 / 拓展"归属；
- ② **分级层**——CEFR 级别 + 年级门槛（如高一≥B1、高二高三≥B2）过滤确定掌握的入门词；
- ③ **历史层**——已掌握的词自动掠过，错过的词优先复现；
- ④ **熟词僻义识别**——一词多义时（如 screen 名词 A2 / 动词 B2），低义项已掌握而高义项未学，则保留并标记。

4.3 记忆闭环开源，而非黑盒

已有方案：多数 AI 学习工具止于"生成清单"。

本项目：清单 → 候选自评 → 默写（中↔英双向，AI 容错判卷，题目含原文例句挖空）→ 错题池 → **SM-2 隔日复习排程**（1→6→15→38→95 天）→ 掌握三分（//）→ 每日自测（≤30 题，含防遗忘抽查）。这一整套以开源形式提供，可被其他教育项目复用。

4.4 词书数据可复现、可交叉验证

所有词书均由 `scripts/` 下构建脚本从**明确许可的公开数据源**重建：高考 / 中考 / 四六级来自 `moread-content` (MIT) + `ECDICT` (MIT) 聚合，CEFR 分级来自 `Words-CEFR-Dataset` (MIT)。

交叉验证证据：本项目生成的高考词表（3837 词）与 `ECDICT` 自带的 `gk` 考试标签（3677 词）**重合 3662 词，覆盖率 95.4%**——两份互相独立的数据源彼此印证，说明词表可信度**可复现、可检验**，而非单一来源的“黑箱词表”。

4.5 面向非技术用户的“最后一公里”

提供 Windows (WebView2 壳) 与 macOS (`.app` / `.command`) 桌面壳、一键启动脚本（含显存检测与自动降级）、单文件夹一体化分发；模型与引擎的获取脚本内建 `sha256` 校验与断点续传。目标是让不写代码的老师也能装上就用。

五、功能完成度与未实现说明

按赛事要求，如实标注完成程度（自评百分比，以"可交付可用"为标准）。

模块	完成度	说明
文本输入 → 五板块提炼	100%	端侧模型结构化输出，长文自动切块合并
照片 / 文档输入	90%	RapidOCR + 视觉双路径已通；双栏排版的分栏列切分未完成，复杂双栏可能串行
三层过滤 + 熟词僻义	100%	规则层确定性实现，含语境义回填
候选自评交互	100%	含"连续 3 次认识自动折叠"
默写（双向 + AI 判卷）	100%	中↔英、原文例句挖空、错题循环到全对
记忆层（SM-2 + 掌握三分 + 每日自测）	100%	算法参数仍有调优空间（见下）
词书系统（5 套 + 导入 + 切换主词书）	100%	注册表驱动，用户可导入自有词书
桌面分发（Win / macOS）	85%	两平台壳与一体化包已可用；单文件 Electron 安装包未做
学习统计报表	30%	仅基础掌握进度与错题统计，趋势图表未做
数据导出（家长 / 老师查看）	0%	未实现
老师端（建班 / 布置 / 统计）	0%	未实现，规划在下一阶段
移动端 App	0%	未实现（架构上模型同构可用，需按平台重写壳）
多省考纲词书自动获取	0%	未实现；因各地考纲多为出版社出版物，需作者自行获取授权

整体自评：核心链路与记忆闭环 100% 可用；工程化分发约 85%；外围（统计 / 导出 / 老师端 / 移动端）基本未做，约占规划总量的四分之一。

已知局限

- SM-2 参数（EF 步长、每日新卡上限）为通行默认值，尚未用自有数据调优
- 双栏 PDF / 照片的列切分未完成，建议单栏截图
- 学习记忆存浏览器 localStorage，换浏览器或清缓存会重置（设计取舍：为隐私零落盘）
- 无 GPU 时走 CPU 层，速度明显下降（功能完整）

六、开源与合规

项	说明
代码许可	Apache-2.0（含专利授权条款，见仓库 LICENSE / NOTICE ）

第三方组件	逐条实测上游 LICENSE 原文并记录于 <code>THIRD_PARTY_NOTICES.md</code> ：Gemma 4 (Apache-2.0)、llama.cpp (MIT)、PaddleOCR / PaddleX / RapidOCR (Apache-2.0)、ECDICT / moread-content / Words-CEFR-Dataset (MIT)、Lucide (ISC)
模型分发	模型权重与推理引擎因体积不随仓库分发，由脚本从上游获取并做 sha256 校验；如随分发包一并提供，将附 Apache-2.0 全文与版权声明
版权隔离	各地官方考纲词汇手册（如上海译文出版社出版的词汇手册） 不随仓库分发 ；软件提供"导入自有词书"能力由使用者自备原件。仓库内词书均来自 MIT 许可的公开数据源
隐私	程序不发起任何上传请求；学习数据仅存本地浏览器

七、后续规划

1. **短期**：双栏 OCR 列切分、学习统计报表、学习数据导出（家长/老师可读）
2. **中期**：老师端（建班、布置材料、查看班级掌握分布）；SM-2 参数按自有数据调优
3. **长期**：移动端（模型同构复用）；更多学科（把"材料 → 清单 → 默写 → 排程"内核迁移到语文古诗文、历史年代线等）