

英语背诵与学习软件（cat paw）

端侧离线 AI 英语背诵工具 · 2026 上海开源软件应用创新大赛 · 开源 AI 工具赛道

项目负责人：康容恺（上海师范大学） | 代码许可：Apache-2.0 | 文档日期：2026-09-26

一句话：把课文或试卷（打字、拍照、传 PDF 都行）丢进去，本机大模型自动提炼**生词·词组·作文金句·搭配·语法**，按**考纲 × CEFR × 学生历史掌握**三层过滤生成背诵清单，再用**默写 + SM-2 间隔复习**闭环到长期记忆。**全程离线运行，学习数据不出机器。**

一、项目背景与痛点

1.1 问题不是“记不住”，而是“背的不是该背的”

中学生英语学习里，真正耗时间的环节不是背，而是**整理**：一篇课文读完后，学生要逐个查词、判断哪些是考纲词、哪些已经会了、哪些是熟词僻义，再抄成清单，最后才开始背。这套手工流程动辄二三十分钟，且高度依赖个人经验——结果是**清单与实际需要错位**：把已经掌握的基础词抄了一堆，真正该攻的搭配和语境义反而漏了。

1.2 现有工具三类错位

类型	做法	错位点
词表类 App	平台预设词书，学生按既定顺序刷	与学生手上这篇课文脱节；无法利用“阅读中遇到”的记忆优势
云 API 类 AI 工具	把课文上传给大模型，返回生词表	隐私风险（学生作文、试卷上传第三方）；断网不可用；按量计费
通用 AI 聊天	对话里让模型“给我提炼生词”	输出不稳定、无分层依据、无记忆闭环，用完即弃

1.3 本项目的取向


把“整理”这一环完全自动化，并且**让分层依据是可解释、可复核的**：每个词都标注归属（考纲 / 拓展）、CEFR 级别、文中义与词典全义的区别；软件不替学生拍板“这个词你会”，而是本着你自己的 ✓/X 自评与默写结果收敛——**宁多勿少，精简交给学习行为。**



软件主界面（本地网页 + 桌面壳，Windows / macOS 免安装一体化分发）

二、技术架构

2.1 总览



2.2 关键设计决策

决策	理由
端侧模型而非云 API	目标场景（学生日常学习）里隐私与"随时可用"是硬需求；Gemma 4 已改为 Apache-2.0，商业与再分发无阻碍
llama.cpp 而非 Ollama	可直接挂 mmpoj 做多模态（拍照识别），且能塞进单文件夹一体化分发；Ollama 保留为可选回退路径
Node 零依赖后端	不需要 npm install，clone 下来就能跑——把"陌生人 5 分钟能用"作为一等目标
词书过滤用规则而非模型	"这个词是不是考纲词"必须确定性、可复现；模型只负责语言理解，判断交给规则层与词书数据
学习记忆放浏览器	学生数据零落盘、零上传；代价是清浏览器数据即重置（已在文档中明示）

2.3 三条输入链路

- 1. **文本**：直接粘贴，长文（>2200 字符）自动切块合并
- 2. **照片**：RapidOCR 快路径（印刷体 ~1-2 秒）→ 质量不足自动切内置视觉模型（复杂版面 / 手写）→ 双保险
- 3. **文档**：PDF（文本型直接抽字 / 扫描版逐页渲染识别）、Word、txt；识别文字回填输入框，可编辑确认后提炼

2.4 可移植性（面向"陌生人能跑"）

后端对 Python 采取**降级优先**的探测链：内嵌 macOS Python → 内嵌 runtime\python → ES_PYTHON 环境变量 → 本机候选 → python3 / python；全部找不到时，照片 OCR 与文档解析自动降级，**粘贴文本与视觉模**

型链路不受影响。模型与引擎不随仓库分发，由 `tools/` 下脚本按 **sha256 逐字节校验**从上游获取；无模型时软件仍可启动（界面、词书、默写、记忆层全部可用）。

三、应用场景

场景	用法与价值
学生自学（主场景）	课后把课文 / 试卷阅读拍照进软件 → 20 秒内得到按自己水平筛过的背诵清单 → 当天默写 + 次日进入 SM-2 复习排程。把"整理"这一环从二三十分钟压到几十秒。
教师布置与讲评	老师把自己选的阅读材料一键生成清单（可复制为文本发群），学生端导入同一篇材料即可对齐；当前版本的班级功能尚未实现（见第五节）。
无网 / 弱网环境	校园网受限、机房不联网、家庭宽带不稳的场景完全可用；模型与词书都在本机。
隐私敏感场景	学生作文、试卷、成绩相关信息全程不出机器——这是很多学校愿意采用本地工具而非云服务的关键理由。
面向开发者的复用	"清单 → 默写 → SM-2 排程"这套记忆内核与词书构建流水线（ <code>scripts/</code> ）都是独立可复用的：其他教育类开源项目可直接接入自己的词表。

四、创新点（对比式说明）

4.1 端侧推理，而非调用云端 API

已有方案：同类背单词 App 与 AI 学习工具普遍把文本上传至云端模型。

不足：隐私外泄风险、断网不可用、按量计费、校园网络受限时不可用。

本项目：Gemma 4 E2B (Apache-2.0) 经 llama.cpp 在本机 GPU 推理，**实测 8-20 秒/篇**（RTX 5060 Laptop 8GB，约 67 tok/s）；断网可用、零调用费用、数据不出机器。

4.2 三层过滤 + 熟词僻义，而非"模型吐一张词表"

已有方案：让模型直接输出"本课生词"，结果依赖模型对"学生水平"的猜测。

不足：不可解释、不可复现、无法对应各地考纲差异、漏掉"认识但新义项没学过"的词。

本项目：

- ① **考纲层**——全文词与主词书做机械扫描比对，确定性地标注"考纲 / 拓展"归属；
- ② **分级层**——CEFR 级别 + 年级门槛（如高一≥B1、高二高三≥B2）过滤确定掌握的入门词；
- ③ **历史层**——已掌握的词自动掠过，错过的词优先复现；
- ④ **熟词僻义识别**——一词多义时（如 screen 名词 A2 / 动词 B2），低义项已掌握而高义项未学，则保留并标记。

4.3 记忆闭环开源，而非黑盒

已有方案：多数 AI 学习工具止于"生成清单"。

本项目：清单 → 候选自评 → 默写（中↔英双向，AI 容错判卷，题目含原文例句挖空）→ 错题池 → **SM-2 隔日复习排程**（1→6→15→38→95 天）→ 掌握三分（//）→ 每日自测（≤30 题，含防遗忘抽查）。这一整套以开源形式提供，可被其他教育项目复用。

4.4 词书数据可复现、可交叉验证

所有词书均由 `scripts/` 下构建脚本从**明确许可的公开数据源**重建：高考 / 中考 / 四六级来自 `moread-content` (MIT) + `ECDICT` (MIT) 聚合，CEFR 分级来自 `Words-CEFR-Dataset` (MIT)。

交叉验证证据：本项目生成的高考词表（3837 词）与 `ECDICT` 自带的 `gk` 考试标签（3677 词）**重合 3662 词，覆盖率 95.4%**——两份互相独立的数据源彼此印证，说明词表可信度**可复现、可检验**，而非单一来源的“黑箱词表”。

4.5 面向非技术用户的“最后一公里”

提供 Windows (WebView2 壳) 与 macOS (`.app` / `.command`) 桌面壳、一键启动脚本（含显存检测与自动降级）、单文件夹一体化分发；模型与引擎的获取脚本内建 `sha256` 校验与断点续传。目标是让不写代码的老师也能装上就用。

五、功能完成度与未实现说明

按赛事要求，如实标注完成程度（自评百分比，以"可交付可用"为标准）。

模块	完成度	说明
文本输入 → 五板块提炼	100%	端侧模型结构化输出，长文自动切块合并
照片 / 文档输入	90%	RapidOCR + 视觉双路径已通；双栏排版的分栏列切分未完成，复杂双栏可能串行
三层过滤 + 熟词僻义	100%	规则层确定性实现，含语境义回填
候选自评交互	100%	含"连续 3 次认识自动折叠"
默写（双向 + AI 判卷）	100%	中↔英、原文例句挖空、错题循环到全对
记忆层（SM-2 + 掌握三分 + 每日自测）	100%	算法参数仍有调优空间（见下）
词书系统（5 套 + 导入 + 切换主词书）	100%	注册表驱动，用户可导入自有词书
桌面分发（Win / macOS）	85%	两平台壳与一体化包已可用；单文件 Electron 安装包未做
学习统计报表	30%	仅基础掌握进度与错题统计，趋势图表未做
数据导出（家长 / 老师查看）	0%	未实现
老师端（建班 / 布置 / 统计）	0%	未实现，规划在下一阶段
移动端 App	0%	未实现（架构上模型同构可用，需按平台重写壳）
多省考纲词书自动获取	0%	未实现；因各地考纲多为出版社出版物，需作者自行获取授权

整体自评：核心链路与记忆闭环 100% 可用；工程化分发约 85%；外围（统计 / 导出 / 老师端 / 移动端）基本未做，约占规划总量的四分之一。

已知局限

- SM-2 参数（EF 步长、每日新卡上限）为通行默认值，尚未用自有数据调优
- 双栏 PDF / 照片的列切分未完成，建议单栏截图
- 学习记忆存浏览器 localStorage，换浏览器或清缓存会重置（设计取舍：为隐私零落盘）
- 无 GPU 时走 CPU 层，速度明显下降（功能完整）

六、开源与合规

项	说明
代码许可	Apache-2.0（含专利授权条款，见仓库 LICENSE / NOTICE ）

第三方组件	逐条实测上游 LICENSE 原文并记录于 <code>THIRD_PARTY_NOTICES.md</code> ：Gemma 4 (Apache-2.0)、llama.cpp (MIT)、PaddleOCR / PaddleX / RapidOCR (Apache-2.0)、ECDICT / moread-content / Words-CEFR-Dataset (MIT)、Lucide (ISC)
模型分发	模型权重与推理引擎因体积不随仓库分发，由脚本从上游获取并做 sha256 校验；如随分发包一并提供，将附 Apache-2.0 全文与版权声明
版权隔离	各地官方考纲词汇手册（如上海译文出版社出版的词汇手册） 不随仓库分发 ；软件提供"导入自有词书"能力由使用者自备原件。仓库内词书均来自 MIT 许可的公开数据源
隐私	程序不发起任何上传请求；学习数据仅存本地浏览器

七、后续规划

- 1. **短期**：双栏 OCR 列切分、学习统计报表、学习数据导出（家长/老师可读）
- 2. **中期**：老师端（建班、布置材料、查看班级掌握分布）；SM-2 参数按自有数据调优
- 3. **长期**：移动端（模型同构复用）；更多学科（把"材料 → 清单 → 默写 → 排程"内核迁移到语文古诗文、历史年代线等）