

作品方案

项目名称：英语背诵与学习软件（cat paw）
赛道：开源 AI 工具赛道
项目负责人：康容恺（上海师范大学）
方案版本：v1.0 · 2026-09-27
代码仓库：github.com/krkldxz/cat-paw-english（AGPL-3.0）
文档日期：2026-09-27

一、作品概述

本项目是一款**面向中学生英语学习的端侧离线 AI 工具**。学生把手上任何英语材料（课文、试卷、外刊文章；打字、拍照、PDF/Word 均可）交给它，由**本机运行的大模型**结合语境提炼出生词、词组、作文金句、搭配与语法点，再按“考纲词书 × CEFR 等级 × 个人历史掌握”三层过滤，形成个性化背诵清单；随后通过**双向默写 + SM-2 间隔复习**闭环到长期记忆。全程离线，学习数据不出机器。

一句话价值主张：把老师“一对多”的考纲提炼，变成学生随时可自助的“一对一”；把原本 30 分钟级的手工整理，压缩到 20 秒。

二、选题背景与需求分析

2.1 评价导向已转向“用语言解决问题”

层面	依据	关键表述
课程	《义务教育英语课程标准（2022 年版）》	目标为 语言能力、文化意识、思维品质、学习能力 四方面核心素养；内容以 主题为引领、含语篇要素 ；要求“在 体验中学习、在实践中运用、在迁移中创新 ”
课程	《普通高中英语课程标准（2017 年版 2020 年修订）》	课程目标从“综合语言运用能力”转向 学科核心素养 ；“语言能力”定义为“在 社会情境中 ……理解和表达意义的能力”
评价	《中国高考评价体系》（教育部考试中心）	“四翼”含 应用性 （强调学以致用）；首创把“ 情境 ”作为 考查载体 ——“在真实的背景下……解决实际问题”
题型	《2020 年全国高考命题评析》	英语科 推出读后续写题型 ，将‘阅读’与‘写作’深度结合”；减少完形、取消短文改错、 增加阅读与写作分值
地方	上海市教委（2025 届春考起）	“听力理解”从笔试 分离并入听说测试机考 （笔试 140→115 分，听说 10→35 分）；官方定性为“ 对学生英语实际应用能力的考察 ”

结论：考察重心已不是“认不认识这个词、记不记得这条释义”，而是**能否在真实语境中理解并表达**。

2.2 现有工具的缺口

主流英语学习 App 普遍采用“词表 → 卡片记忆 → 间隔重复 → 游戏化打卡”模式，优化目标是“记住更多单词”，但存在两个缺口：

1. **只注重单词记忆，不注重运用**——训练的是“词—义”连线，而考试考察的是“语境 → 意义 → 表达”的完整链条；一词多义与熟词僻义尤其吃亏。

2. **缺乏定制化语境**——提供的是通用词表，而非与学生正在面对的材料、日常生活、自身经历绑定的语境。

2.3 学校已在做的"提炼"及其边界（本项目的直接切入点）

学校普遍采用"英语提炼"帮助记单词：老师针对卷子与考题提炼单词、词组与考点。方法有效，但边界明确：

	学校的提炼	学生自己刷题 / 阅读时
谁做提炼	老师（专业、有经验）	没有人 ——只能自己查、凭感觉判断
面向谁	面向大众 ：照顾不同层次，取舍偏共性	本应 面向我自己 ：只看未掌握的
覆盖材料	老师选定并讲解的材料	学生手上任何材料

核心矛盾：老师的提炼是"一对多"的，学生自主学习需要"一对一"的——但一对一的成本，老师付不起。

2.4 目标用户

主要用户为**初高中学生**（课后自学、考前复习、兴趣阅读）；次要用户为**教师与家长**（当前版本以学生自学为设计中心，教师端功能未实现，见 §8）。

三、总体方案

3.1 方案主线

输入（粘贴 / 拍照 / PDF-Word）

→ 端侧 LLM 结合语境的结构化提炼（五板块）

→ 规则引擎三层过滤（考纲词书 × CEFR × 历史掌握）+ 熟词僻义识别

→ 候选自评（学生自检，不看答案判断）

→ 双向默写（AI 容错判卷 + 原文例句挖空）

→ SM-2 间隔复习 + 掌握三分 + 每日自测（≤30 题）

3.2 关键技术选型

决策	选择	理由
模型部署	端侧推理 （Gemma 4 E2B, Apache-2.0 + llama.cpp）	隐私（作文/试卷不外传）、断网可用、零调用费用；实测 13–15 秒/篇
归属判定	规则层 而非模型	全文词与主词书机械比对，结果确定、可解释、可复核；避免模型"看着像就归类"
作业分层	考纲 × CEFR × 历史掌握 三层 + 熟词僻义	对应"课内/拓展"的真实需求；熟词僻义是同类工具普遍漏掉的一类考点
记忆算法	SM-2 间隔复习 + 掌握三分	成熟、可解释、无需训练数据；答错重置、答对指数放宽
交付形态	封装桌面软件 （内置运行时与模型）	让不写代码的老师与学生能直接用；源码同步以 AGPL-3.0 开源
数据来源	公开许可数据集重建词书（MIT 来源）+ 用户自备导入	版权干净；官方考纲手册不随软件分发

3.3 覆盖范围（明确边界）

- 覆盖：提炼 · 词书 · 候选自评 · 默写判卷 · 记忆复习 · 阅读 · 聊天（语伴纠错、作文批改）
- 不覆盖：听力（本轮未做）；教师端班级管理（未实现）；移动端（未开始）

四、实施计划与里程碑

4.1 已完成（2026-09）

阶段	内容	量化结果
仓库化	建立 git 仓库、选定许可证、清理一次性脚本与大文件	公开树 38 MB / 104 文件 ，零脚本噪声
词书系统	通用化重构：内置 5 本 + 导入（PDF/JSON/文本）+ 设为主词书	回归 18/18 通过
端到端加固	错误处理、JSON 截断修复、响应头守卫、全局兜底	端到端回归 20/20 通过
陌生人可用	干净 clone 实测可启动；首次启动引导下载 AI	实测：clone → 启动成功，5 本词书加载完毕
文档	作品介绍、设计文档、说明书 v8.0、README、合规声明	4 份 PDF + 6 份 Markdown

4.2 交付物

交付物	说明
开源仓库	完整源码 + 模型/引擎获取脚本（sha256 校验）+ 三步上手文档； 38 MB
封装桌面软件	单文件夹免安装（约 6.69 GB，内置 Node/Python 运行时与模型），Windows <code>.exe</code> / macOS <code>.app</code> 双击即用
文档	作品方案（本文）· 作品介绍 · 设计文档 · 说明书 · 第三方许可声明

4.3 后续里程碑

- 短期：双栏 OCR 列切分、PDF 长词跨行拼接
- 中期：SM-2 参数按自有数据调优；词书扩充与自定义题型
- 长期：移动端（模型同构复用，采用首次启动按需下载模型的方案）；内核迁移到其他学科（古诗文、历史年代线等"材料 → 清单 → 默写 → 排程"同构场景）

4.4 资源需求

单机可完成：消费级笔记本（RTX 5060 Laptop 8 GB 已实测）；无 GPU 可走 CPU 层（较慢）；无云算力、无 API 费用。

五、可行性与验证

5.1 技术可行性（均为本机实测）

指标	实测值
引擎冷启动	8 秒

文本提炼（约 90 词短文）	13–15 秒
图片识别	13.9 秒
PDF 词汇手册解析（87 页）	4.6 秒 → 3311 词
引擎显存占用	约 2.9 GB（不足自动降级 GPU 层数）

5.2 数据可行性

词书全部由脚本从**明确许可的公开数据源**重建，并与独立数据源 ECDICT **交叉验证重合 95.4%**；与手工核对版本比对覆盖率 **99.2%**。官方考纲手册因版权不随软件分发，改由用户导入自备原件（PDF 直接可导）。

5.3 使用可行性

- **零环境依赖**：封装版内置运行时与模型，双击即用、无需账号、无需联网
- **渐进可用**：素材集未就绪时，仓库克隆即可启动"最小版"（界面 / 词书 / 默写 / 记忆全部可用），AI 功能待首次启动下载完成后自动启用

5.4 开源可行性

代码 **AGPL-3.0**：他人分发生作品或提供网络服务须同样开源，防止闭源商用；作者保留双授权权利与名称/标识权利。

六、风险与应对

风险	影响	应对
模型权重体积（5.2 GB）导致评委不愿下载	影响"上手体验"第一印象	仓库克隆即可启动最小版；首次启动提供一键下载（断点续传 + sha256）；演示视频同步呈现完整体验
端侧模型能力弱于云模型	提炼质量	用 规则层 承担归属判定与分层（确定性），模型只做语言理解；输出走健壮解析与自动重试
图片/PDF 版式复杂（双栏、扫描件）	识别质量下降	内置乱码检测与头尾修补、自动重试；扫描件明确提示改用拍照；已知限制如实标注
隐私与合规	学校不敢用	全程离线、服务仅监听本机、无上传路径；数据不出机器
版权风险（词书来源）	合规红线	官方考纲手册不随仓库/软件分发；词书来自 MIT 许可数据源；提供用户自备导入能力
维护可持续性	长期质量	全部构建脚本入库可复现；两条回归测试（20 项 + 18 项）；文档体系齐全

七、创新点（对比式）

1. **把老师"一对多"的提炼变成学生可自助的"一对一"**——已有方案是学校提炼（面向大众、限于老师选定材料）与通用词表；本项目用端侧模型把同等质量的语境化提炼交给学生本人：材料任意、分层按己、定位自助自检。
2. **端侧推理**——数据不出机器、断网可用、零调用费用；对学校而言这是"敢用"的前提。
3. **分层可解释、数据可复现**——归属判定交规则层；CEFR + 年级门槛 + 熟词僻义；词书与独立数据源交叉验证 95.4%。

4. **除听力外的完整闭环且开源可复用**——提炼 → 自评 → 默写（AI 容错判卷、例句挖空）→ 错题池 → SM-2 → 每日自测，另含阅读与聊天（语伴纠错、作文批改）。
5. **用兴趣换内驱力**——学生自选感兴趣题材作为阅读材料，同一套机制照常运转。
6. **封装交付**——内置运行时与模型，不写代码的人也能直接用。

八、完成程度与未实现说明

模块	完成度	说明
文本输入 → 五板块提炼	100%	端侧模型结构化输出，长文自动切块合并
照片 / 文档输入	90%	双路径已通；双栏分栏列切分未完成
三层过滤 + 熟词僻义	100%	规则层确定性实现，含语境义回填
候选自评交互	100%	含"连续 3 次认识自动折叠"
默写（双向 + AI 判卷）	100%	中↔英、原文例句挖空、错题循环到全对
记忆层（SM-2 + 掌握三分 + 每日自测）	100%	参数仍有调优空间
词书系统（5 套 + 导入 + 切换主词书）	100%	注册表驱动，可导入自有词书
桌面分发（Windows / macOS）	85%	两平台壳与一体化包可用；单文件安装包未做
移动端 App	0%	未开始（需按平台重写壳 + 模型按需下载方案）
多省考纲词书自动获取	0%	未实现（各地考纲多为出版物，需自行获取授权）

整体自评：核心链路与记忆闭环 **100% 可用**；工程化分发约 **85%**；移动端等扩展方向尚未开始。

九、开源与合规

项	说明
代码许可	AGPL-3.0 (SPDX: AGPL-3.0-only) ——强 copyleft + 网络条款
商业授权	作者保留双授权权利；闭源商业使用（含上架应用商店、提供网络服务）可另行取得授权
名称与标识	保留所有权利，不随代码许可授权
第三方组件	逐条实测上游 LICENSE 原文并记录于 THIRD_PARTY_NOTICES.md：Gemma 4 (Apache-2.0) · llama.cpp (MIT) · PaddleOCR/PaddleX/RapidOCR (Apache-2.0) · ECDICT / moread-content / Words-CEFR-Dataset (MIT) · Lucide (ISC)
模型分发	权重与引擎不随仓库分发，由脚本从上游获取并做 sha256 校验
版权隔离	各地官方考纲词汇手册不随仓库与软件分发，改由用户导入自备原件；仓库内词书均来自 MIT 许可公开数据源
隐私	不发起任何上传请求；服务仅监听本机地址；学习数据存本地浏览器

十、附录

10.1 相关文档

文档	用途
作品介绍.pdf	参赛作品介绍（背景 / 技术架构 / 应用场景 / 创新点）
docs/设计文档.md + PDF	系统设计：架构、模块、接口、算法、容错
说明书-2026-09-26.md	使用说明书 v8.0（含界面截图）
README.md	仓库门面：交付形态、运行前提、快速开始、完成度
THIRD_PARTY_NOTICES.md	第三方组件与许可逐条清单

10.2 验证命令

```
node scripts/verify_e2e.js      # 端到端回归 20 项
node scripts/verify_books.js    # 词书系统验证 18 项
```

10.3 引用来源

1. 《义务教育英语课程标准（2022 年版）》·教育部，教材〔2022〕2 号 ·
<https://www.canedu.org.cn/site/content/6623.html>
2. 《普通高中英语课程标准（2017 年版 2020 年修订）》·教育部，教材〔2020〕3 号 ·
http://www.moe.gov.cn/srcsite/A26/s8001/202006/t20200603_462199.html
3. 《中国高考评价体系》·教育部考试中心 ·
http://www.moe.gov.cn/jyb_xwfb/s5147/202001/t20200108_414689.html
4. 《2020 年全国高考命题评析》·教育部考试中心 ·
http://www.moe.gov.cn/jyb_xwfb/moe_2082/zl_2020n/2020_zl38/202007/t20200710_471210.html
5. 2025 年上海春考英语听力改机考 · 上海市政府网站（转载解放日报） ·
<https://www.shanghai.gov.cn/nw4411/20241227/86a189c138724e97abbdca422bfe77d8.html>