

作品方案

项目名称：英语背诵与学习软件（cat paw）
赛道：开源 AI 工具赛道
项目负责人：康容恺（上海师范大学）
方案版本：v1.0 · 2026-09-27
代码仓库：github.com/krkldxz/cat-paw-english（AGPL-3.0）
文档日期：2026-09-27

一、作品概述

本项目是一款**面向中学生英语学习的端侧离线 AI 工具**。学生把手上任何英语材料（课文、试卷、外刊文章；打字、拍照、PDF/Word 均可）交给它，由**本机运行的大模型**结合语境提炼出生词、词组、作文金句、搭配与语法点，再按“考纲词书 × CEFR 等级 × 个人历史掌握”三层过滤，形成个性化背诵清单；随后通过**双向默写 + SM-2 间隔复习**闭环到长期记忆。全程离线，学习数据不出机器。

一句话价值主张：把老师“一对多”的考纲提炼，变成学生随时可自助的“一对一”；把原本 30 分钟级的手工整理，压缩到 20 秒。

二、选题背景与需求分析

2.1 评价导向已转向“用语言解决问题”

层面	依据	关键表述
课程	《义务教育英语课程标准（2022 年版）》	目标为 语言能力、文化意识、思维品质、学习能力 四方面核心素养；内容以 主题为引领、含语篇要素 ；要求“在 体验中学习、在实践中运用、在迁移中创新 ”
课程	《普通高中英语课程标准（2017 年版 2020 年修订）》	课程目标从“综合语言运用能力”转向 学科核心素养 ；“语言能力”定义为“ 在社会情境中……理解和表达意义的能力 ”
评价	《中国高考评价体系》（教育部考试中心）	“四翼”含 应用性 （强调学以致用）；首创把“ 情境 ”作为 考查载体 ——“在真实的背景下……解决实际问题”
题型	《2020 年全国高考命题评析》	英语科 推出读后续写题型 ，将‘阅读’与‘写作’深度结合”；减少完形、取消短文改错、 增加阅读与写作分值
地方	上海市教委（2025 届春考起）	“听力理解”从笔试 分离并入听说测试机考 （笔试 140→115 分，听说 10→35 分）；官方定性为“ 对学生英语实际应用能力的考察 ”

结论：考察重心已不是“认不认识这个词、记不记得这条释义”，而是**能否在真实语境中理解并表达**。

2.2 现有工具的缺口

主流英语学习 App 普遍采用“词表 → 卡片记忆 → 间隔重复 → 游戏化打卡”模式，优化目标是“记住更多单词”，但存在两个缺口：

1. **只注重单词记忆，不注重运用**——训练的是“词—义”连线，而考试考察的是“语境 → 意义 → 表达”的完整链条；一词多义与熟词僻义尤其吃亏。

2. **缺乏定制化语境**——提供的是通用词表，而非与学生正在面对的材料、日常生活、自身经历绑定的语境。

2.3 学校已在做的"提炼"及其边界（本项目的直接切入点）

学校普遍采用"英语提炼"帮助记单词：老师针对卷子与考题提炼单词、词组与考点。方法有效，但边界明确：

	学校的提炼	学生自己刷题 / 阅读时
谁做提炼	老师（专业、有经验）	没有人 ——只能自己查、凭感觉判断
面向谁	面向大众 ：照顾不同层次，取舍偏共性	本应 面向我自己 ：只看未掌握的
覆盖材料	老师选定并讲解的材料	学生手上任何材料

核心矛盾：老师的提炼是"一对多"的，学生自主学习需要"一对一"的——但一对一的成本，老师付不起。

2.4 目标用户

主要用户为**初高中学生**（课后自学、考前复习、兴趣阅读）；次要用户为**教师与家长**（当前版本以学生自学为设计中心，教师端功能未实现，见 §7）。

三、总体方案

3.1 方案主线

输入（粘贴 / 拍照 / PDF-Word）

→ 端侧 LLM 结合语境的结构化提炼（五板块）

→ 规则引擎三层过滤（考纲词书 × CEFR × 历史掌握）+ 熟词僻义识别

→ 候选自评（学生自检，不看答案判断）

→ 双向默写（AI 容错判卷 + 原文例句挖空）

→ SM-2 间隔复习 + 掌握三分 + 每日自测（≤30 题）

3.2 关键技术选型

决策	选择	理由
模型部署	端侧推理 （Gemma 4 E2B, Apache-2.0 + llama.cpp）	隐私（作文/试卷不外传）、断网可用、零调用费用；实测 13–15 秒/篇
归属判定	规则层 而非模型	全文词与主词书机械比对，结果确定、可解释、可复核；避免模型"看着像就归类"
作业分层	考纲 × CEFR × 历史掌握 三层 + 熟词僻义	对应"课内/拓展"的真实需求；熟词僻义是同类工具普遍漏掉的一类考点
记忆算法	SM-2 间隔复习 + 掌握三分	成熟、可解释、无需训练数据；答错重置、答对指数放宽
交付形态	封装桌面软件 （内置运行时与模型）	让不写代码的老师与学生能直接用；源码同步以 AGPL-3.0 开源
数据来源	公开许可数据集重建词书（MIT 来源）+ 用户自备导入	版权干净；官方考纲手册不随软件分发

3.3 覆盖范围（明确边界）

- **覆盖**：提炼 · 词书 · 候选自评 · 默写判卷 · 记忆复习 · 阅读 · 聊天（语伴纠错、作文批改）
- **不覆盖**：**听力**（本轮未做）；教师端班级管理（未实现）；移动端（未开始）

四、可行性与验证

5.1 技术可行性（均为本机实测）

指标	实测值
引擎冷启动	8 秒
文本提炼（约 90 词短文）	13-15 秒
图片识别	13.9 秒
PDF 词汇手册解析（87 页）	4.6 秒 → 3311 词
引擎显存占用	约 2.9 GB（不足自动降级 GPU 层数）

5.2 数据可行性

词书全部由脚本从**明确许可的公开数据源**重建，并与独立数据源 ECDICT **交叉验证重合 95.4%**；与手工核对版本比对覆盖率 **99.2%**。官方考纲手册因版权不随软件分发，改由用户导入自备原件（PDF 直接可导）。

5.3 使用可行性

- **零环境依赖**：封装版内置运行时与模型，双击即用、无需账号、无需联网
- **渐进可用**：素材集未就绪时，仓库克隆即可启动"最小版"（界面 / 词书 / 默写 / 记忆全部可用），AI 功能待首次启动下载完成后自动启用

5.4 开源可行性

代码 **AGPL-3.0**：他人分发行生作品或提供网络服务须同样开源，防止闭源商用；作者保留双授权权利与名称/标识权利。

五、风险与应对

风险	影响	应对
端侧模型能力弱于云模型	提炼质量	用 规则层 承担归属判定与分层（确定性），模型只做语言理解；输出走健壮解析与自动重试
图片/PDF 版式复杂（双栏、扫描件）	识别质量下降	内置乱码检测与头尾修补、自动重试；扫描件明确提示改用拍照；已知限制如实标注
隐私与合规	学校不敢用	全程离线、服务仅监听本机、无上传路径；数据不出机器
版权风险（词书来源）	合规红线	官方考纲手册不随仓库/软件分发；词书来自 MIT 许可数据源；提供用户自备导入能力
维护可持续性	长期质量	全部构建脚本入库可复现；两条回归测试（20 项 + 18 项）；文档体系齐全

六、创新点（对比式）

- 1. 把老师"一对多"的提炼变成学生可自助的"一对一"——已有方案是学校提炼（面向大众、限于老师选定材料）与通用词表；本项目用端侧模型把同等质量的语境化提炼交给学生本人：材料任意、分层按己、定位自助自检。
- 2. 端侧推理——数据不出机器、断网可用、零调用费用；对学校而言这是"敢用"的前提。
- 3. 分层可解释、数据可复现——归属判定交规则层；CEFR + 年级门槛 + 熟词僻义；词书与独立数据源交叉验证 95.4%。
- 4. 除听力外的完整闭环且开源可复用——提炼 → 自评 → 默写（AI 容错判卷、例句挖空）→ 错题池 → SM-2 → 每日自测，另含阅读与聊天（语伴纠错、作文批改）。
- 5. 用兴趣换内驱力——学生自选感兴趣题材作为阅读材料，同一套机制照常运转。
- 6. 封装交付——内置运行时与模型，不写代码的人也能直接用。

七、完成程度与未实现说明

模块	完成度	说明
文本输入 → 五板块提炼	100%	端侧模型结构化输出，长文自动切块合并
照片 / 文档输入	90%	双路径已通；双栏分栏列切分未完成
三层过滤 + 熟词僻义	100%	规则层确定性实现，含语境义回填
候选自评交互	100%	含"连续 3 次认识自动折叠"
默写（双向 + AI 判卷）	100%	中↔英、原文例句挖空、错题循环到全对
记忆层（SM-2 + 掌握三分 + 每日自测）	100%	参数仍有调优空间
词书系统（5 套 + 导入 + 切换主词书）	100%	注册表驱动，可导入自有词书
桌面分发（Windows / macOS）	85%	两平台壳与一体化包可用；单文件安装包未做
移动端 App	0%	未开始（需按平台重写壳 + 模型按需下载方案）
多省考纲词书自动获取	0%	未实现（各地考纲多为出版物，需自行获取授权）

整体自评：核心链路与记忆闭环 100% 可用；工程化分发约 85%；移动端等扩展方向尚未开始。

八、开源与合规

项	说明
代码许可	AGPL-3.0 (SPDX: AGPL-3.0-only) ——强 copyleft + 网络条款
商业授权	作者保留双授权权利；闭源商业使用（含上架应用商店、提供网络服务）可另行取得授权
名称与标识	保留所有权利，不随代码许可授权
第三方组	逐条实测上游 LICENSE 原文并记录于 THIRD_PARTY_NOTICES.md：Gemma 4 (Apache-2.0) · llama.cpp (MIT) · PaddleOCR/PaddleX/RapidOCR (Apache-2.0) · ECDICT / moread-content / Words-CEFR-Dataset

件	(MIT) · Lucide (ISC)
模型分发	权重与引擎不随仓库分发，由脚本从上游获取并做 sha256 校验
版权隔离	各地官方考纲词汇手册不随仓库与软件分发，改由用户导入自备原件；仓库内词书均来自 MIT 许可公开数据源
隐私	不发起任何上传请求；服务仅监听本机地址；学习数据存本地浏览器

九、附录

9.1 相关文档

文档	用途
作品介绍.pdf	参赛作品介绍（背景 / 技术架构 / 应用场景 / 创新点）
docs/设计文档.md + PDF	系统设计：架构、模块、接口、算法、容错
说明书-2026-09-26.md	使用说明书 v8.0（含界面截图）
README.md	仓库门面：交付形态、运行前提、快速开始、完成度
THIRD_PARTY_NOTICES.md	第三方组件与许可逐条清单

9.2 验证命令

```
node scripts/verify_e2e.js      # 端到端回归 20 项
node scripts/verify_books.js    # 词书系统验证 18 项
```

9.3 引用来源

1. 《义务教育英语课程标准（2022 年版）》·教育部，教材〔2022〕2 号 ·
<https://www.canedu.org.cn/site/content/6623.html>
2. 《普通高中英语课程标准（2017 年版 2020 年修订）》·教育部，教材〔2020〕3 号 ·
http://www.moe.gov.cn/srcsite/A26/s8001/202006/t20200603_462199.html
3. 《中国高考评价体系》·教育部考试中心 ·
http://www.moe.gov.cn/jyb_xwfb/s5147/202001/t20200108_414689.html
4. 《2020 年全国高考命题评析》·教育部考试中心 ·
http://www.moe.gov.cn/jyb_xwfb/moe_2082/zt_2020n/2020_zl38/202007/t20200710_471210.html
5. 2025 年上海春考英语听力改机考 · 上海市政府网站（转载解放日报） ·
<https://www.shanghai.gov.cn/nw4411/20241227/86a189c138724e97abbdca422bfe77d8.html>