

英语背诵与学习软件 · 设计文档

版本 v1.0 · 2026-09-26 · 对应代码提交 0f2a009

相关文档: [需求文档-2026-09-03](#) · [说明书-2026-09-05](#) (使用手册) · [README](#) (交付形态与快速开始)

本文描述**如何实现**; 需求与功能边界见需求文档与 README。


1. 设计目标与约束

约束	来源	设计后果
数据不出机器	学校对题目/试卷/作文的隐私诉求	模型本机推理, 服务只监听 127.0.0.1, 无任何上传路径
断网可用	校园网受限、机房不联网	模型、引擎、运行时全部随包分发, 无账号、无 API Key
消费级硬件可跑	学生笔记本 (实测 RTX 5060 Laptop 8GB)	Gemma 4 E2B (Q4_K_M, 约 2.9 GB) + llama.cpp; 启动前显存自检, 不足则自动降级 GPU 层数
零依赖后端	让"陌生人 5 分钟能跑"	Node 单文件服务, 不使用任何 npm 依赖 (仅 Node 内置模块)
非技术用户能用	学生与老师	以封装桌面软件交付 (双击即用), 源码另供开发者
可解释、可复现	学习结论要能被复核	归属判定交给规则层而非模型; 词书由脚本从明确许可的数据源重建

非目标: 多用户/账号体系、云端同步、听力训练 (见 §12) 。

2. 总体架构





verify_books.js	词书系统验证（18 项）
_archive/	一次性脚本归档（不参与运行）
data/	词书与用户数据
models/	模型权重与 OCR onnx
docs/	文档（作品介绍、本设计文档、项目卡）

4. 核心模块设计

4.1 输入链路（三条，互不阻塞）

输入	路径	依赖	降级
文本粘贴	前端 → /api/extract → 引擎	仅引擎	引擎不可用 → 提示启动引擎
图片	前端 → /api/file-text → 图像处理后交引擎 (mmproj 视觉)	引擎（视觉）	Python 缺席不影响视觉路径
PDF / Word	前端 → /api/file-text → extract_text.py (pymupdf / docx)	Python + pymupdf	无 Python → 明确提示"可用文本粘贴或拍照"

图片处理链（§6 函数清单 中 12 个函数）：先在服务端做预处理与裁剪（`prepImage / cropTop / cropBand`），识别后用**乱码检测**（`isGarbled / badishLine / countLeadBad / countTailBad`）判定质量，再走**头尾修补**（`refineHeadTail / topStripRecovery / v4Supplement / visionStripSupplement`），直到文本可用。这是为了对付真实拍照的常见问题：倾斜、裁到一半、页眉页脚混入、低对比。

4.2 提炼模块

- **提示词**：`buildSystemPrompt(grade)` 按年级注入要求；输出固定 JSON 五板块 `vocabulary / phrases / golden_sentences / collocations / grammar`。
- **长文分块**：`splitText`，单块阈值 `MAX = 2000` 字符；`extractData` 分块提炼后**按 key 去重合并**（词形 / 词组 / 句子 / 搭配 / 语法点各一套 `Set`）。
- **健壮解析**（关键容错）：`parseModelJson` 逐级修复——
 1. 去 markdown 围栏 → 直接 `JSON.parse`
 2. 取首个 `{` 起、末个 `}` 止
 3. 扫描字符串状态与括号栈，在**最后一个结构完整处**截断并补齐闭括号
 4. 仍失败则回退丢弃尾部残片重试
 5. 全部失败 → 提高 token 预算（4500 → 6000）**自动重试一次**
- **token 预算**：默认 2000（兼容旧调用），提取用 **4500**，重试用 **6000**；判卷补义 3500，视觉识别 3000–4000。

4.3 候选分层引擎（本项目的核心算法）

`buildCandidates(text, annotated, grade, validBooks)` 产出学生自评的候选池，**三层来源**：

主词书（primary）	— <code>scanBook(text, grade)</code>	→ scope「考纲」
副词书（leveled）	— <code>scanLeveled(text, rec, grade)</code>	→ scope「CEFR」等

副词书 (list) —— scanList(text, rec, grade) → scope 「CET4/6」等
表外词 —— 引擎首轮产出的生词 → scope 「拓展」

归属判定 (规则层, 不由模型决定): 使用 buildBookIndex(book) 建立的索引——

- info: 词形 → 词条 (含**主形与括号内变体**: abandon、a(an)、take(off) 三类都建索引)
- phraseKeys: 词组集合 (归一化大小写与括号)

判定结果: 考纲 (在主词书) / 拓展 (不在任何词书) / 副词书层 (在副词书)。

年级门槛 (KEEP_LINE + LVL_N):

小学 A1 · 初中 A1 · 高一 A2 · 高二 B1 · 高三 B1 · 大学 B2; CEFR 数值 A1=1 ... C2=6。

scanLeveled 只排除**确定入门**的词 (LVL_N[maxLevel] < nKeep), 并把已在主词书的词让给主词书层。

熟词僻义识别: 当某词在 CEFR 记录中跨多个等级 (minLevel ≠ maxLevel), 若**低义项已被年级门槛覆盖 (说明学过) 而高义项未学**, 则保留——即"认识这个词, 但没学过这个义项"。这是同类工具普遍漏掉的一类考点。

语境补义: fillContextMeanings 对无释义的候选, 把候选词与原文 (截断) 交给引擎补义与例句, 避免"清单里只有词没有义"。

4.4 词书系统

- **注册表**: BOOKS: Map<id, {id, name, kind, book, index, path, removable}>; loadAllBooks() 启动时加载内置词书并**发现** data/ 下新增的词书文件。
- **内置 5 本**: cefr (CEFR 分级 7035 词) / cet4 (5183) / cet6 (5974) / zk 中考 (1600) / gk 高考 (3837)。
- **主词书**: PRIMARY_ID, 持久化在 data/settings.json; 未设置时优先 gk。
- **导入**: importBook 支持 ① 标准 JSON 词书 ② 裸数组 ③ 纯文本词表 (每行一词, 制表符/多空格/冒号分隔释义); importBookFromPdf 支持 **PDF 词汇手册** (见 §4.5)。导入落 data/books/<id>.json, removable=true。
- **切换主词书即换考纲**: /api/books/primary 后, 下一次提炼的「考纲」层即来自新主词书 (实测: 导入自定义 8 词词书 → 设为主词书 → 提炼的考纲层来自该书且释义取自该书)。

4.5 PDF 词汇手册导入

```
POST /api/books/import {name, filename, pdfBase64}
→ 落临时文件 → scripts/book_from_pdf.py --out <json>
→ {type:"ok", words[], stats} → importBook()
```

book_from_pdf.py 策略: **pymupdf find_tables()** **表格优先** (词汇手册多为表格), 取"最像单词"的列作词、含中文的列作释义; 表格不足 50 条时退化**逐行解析** (词 + 音标 [...] //.../ + 释义, 过滤页眉页码与章节标记)。文字层不足的**扫描版**返回 {type:"scan"}, 服务端给出可操作提示 (改用拍照识别)。

陷阱记录: find_tables 会向 stdout 打印提示且可能是 UTF-16, 故结果走 --out 文件、Python 侧全程转走 stdout。

4.6 默写与判卷

- **双向默写**：中→英（看释义写词）、英→中（看词写义）；支持**原文例句挖空**（把该词在原句位置替换为空格，提供上下文线索）。
- **判卷**：`/api/judge-zh` 交引擎做**容错判卷**（拼写近似、大小写、词形变化、中文近义表述均视为正确），避免机械字符串比对挫伤学习。
- **干扰项池**：`makeDistractors()` 从**注册表内任意词书**随机抽释义，供四选一题型（不再依赖任何单一词书）。

4.7 记忆层（前端为主）

- **SM-2 间隔复习**：按掌握度维护 `ease` 与间隔，到期自动进入当日复习队列。
- **掌握三分**：`未学 / 见过(seen) / 已掌握(master)`；`seen && !master` 计入"学习中"。
- **错题池**：默写/判卷判错自动入池，优先复现。
- **每日自测**：上限 ≤ 30 题，避免过载；`/api/read` 与 `/api/util` 提供朗读与工具能力。
- **本地存储**：状态存 `localStorage`（`es_streak` 连续天数、`es_grade` 年级、`es_books` 勾选词书、`es_persona` 语伴人格、`es_mem_v2_*` 掌握记录等）——**学习数据不落服务端**，是"数据不出机器"的最后一环。

4.8 聊天（语伴/作文）

`/api/chat/open`（开题/初始化）、`/api/chat`（对话，按 `es_persona` 切换语伴人格与纠错力度）、`/api/essay`（作文批改）。三者均走本机引擎。

5. 接口设计（18 个）

方法	路径	用途
POST	<code>/api/extract</code>	文本 → 五板块 + 候选池 + 干扰项
POST	<code>/api/file-text</code>	文件/图片 → 文本（PDF/DOCX/TXT/图片视觉）
POST	<code>/api/word-meanings</code>	批量取词义（候选补义）
POST	<code>/api/judge-zh</code>	中文答题容错判卷
POST	<code>/api/mode</code>	读写运行模式（ <code>data/settings.json</code> ）
GET	<code>/api/health</code>	引擎状态 + 词书摘要 + 主词书
GET	<code>/api/books</code>	词书列表（含 <code>primary / removable</code> 标记）
POST	<code>/api/books/import</code>	添加词书（JSON / 文本 / PDF）
POST	<code>/api/books/primary</code>	设为主词书
POST	<code>/api/books/delete</code>	删除用户词书
GET	<code>/api/book/<id></code>	翻看词书（ <code>letter= / q=</code> 搜索）
GET	<code>/api/word</code>	单词详情
POST	<code>/api/chat/open · /api/chat · /api/essay</code>	语伴对话 / 作文批改
POST	<code>/api/read · /api/util</code>	朗读 / 工具
GET	<code>/</code>	前端页面

统一约定：`Content-Type: application/json; charset=utf-8`；错误返回 `{ok:false, error}`；**请求体上限**：旧路由 8 MB，词书导入（含 PDF base64）60 MB。

6. 可靠性与容错设计（★ 实际踩过的坑都在这里）

风险	设计对策	触发动机
模型输出被截断/夹带说明	<code>parseModelJson</code> 逐级修复 + 提高预算自动重试 (\$4.2)	实测：一篇课文曾因 <code>max_tokens=2000</code> 截断， <code>JSON.parse</code> 抛错导致单次失败
响应头发送后再抛错	提取处理器改为 全部算完再 <code>writeHead</code> ； <code>catch</code> 增加 <code>res.headersSent</code> 守卫	实测：先发 200 再计算，中途抛错时 <code>catch</code> 二次 <code>writeHead</code> → <code>ERR_HTTP_HEADERS_SENT</code> 未捕获，整个服务进程退出
任何未捕获异常都不该让本地服务整体死亡	注册 <code>process.on('uncaughtException')</code> 与 <code>'unhandledRejection'</code> ，记录并保持存活	桌面软件没有“运维重启”，单请求失败不应演化成服务不可用
引擎未启动 / 崩溃	<code>engineAlive()</code> 探活；失败回退 <code>ollamaChat</code> （本机 Ollama）；均不可用则给出明确指引	—
显存不足	启动前 <code>nvidia-smi</code> 自检：空闲 <4.5 GB 时 <code>-ngl 25</code> 降级并把提示写进启动日志	避免与 ComfyUI 等 GPU 程序争抢导致崩溃
本机无 Python / 缺包	<code>findPy()</code> 探测链（内置 → 环境变量 → 常见 <code>venv</code> ）； <code>PY_RESOLVED</code> 为空时文档解析与 OCR 降级， 文本与视觉路径 不受影响	让“没装环境的电脑”也能用核心功能
扫描版 PDF	<code>extract_text.py</code> 判定文字层过少 → <code>{type:"scan"}</code> ；服务端转译为可读提示	不静默失败

7. 性能与资源实测

项目	实测值	环境
引擎冷启动	8 秒	RTX 5060 Laptop 8GB
文本提炼（约 90 词短文）	13–15 秒	同上， <code>-ngl 99 -c 8192</code>
长文提炼（重复 9 段）	13–14 秒（含分块合并）	—
图片识别（6 KB 测试图）	13.9 秒	视觉路径（ <code>mmproj</code> ）
PDF 词汇手册解析（87 页）	4.6 秒 → 3311 词	表格模式
模型占用	2.9 GB（Q4_K_M）+ <code>mmproj</code>	显存
封装包体积	约 6.69 GB（含运行时与模型）	单文件夹免安装
源码仓库	34.9 MB / 94 文件	适合公开托管

回归测试：`scripts/verify_e2e.js`（端到端 20 项）· `scripts/verify_books.js`（词书 18 项）。

8. 安全与合规设计

- 1. **无上传路径**：服务只监听回环地址；代码中不存在向外部域名发送数据的调用；学习数据存 `localStorage` 。
- 2. **许可合规**：代码 AGPL-3.0（闭源商业使用需另行取得商业授权；名称与标识保留所有权利）；第三方组件逐条实测上游许可（Gemma 4 = Apache-2.0 / llama.cpp = MIT / PaddleOCR·RapidOCR = Apache-2.0 / 词书数据源 = MIT），逐条列于 `THIRD_PARTY_NOTICES.md` 。
- 3. **版权隔离**：模型权重与引擎因体积不随仓库分发；**各地官方考纲词汇手册因版权不随仓库分发——**改为"由用户导入自有词书"（`/api/books/import` 支持 PDF/JSON/文本），这是产品能力而非妥协。
- 4. **不采集**：无账号、无遥测、无广告。

9. 已知限制（如实列出）

限制	现状	计划
双栏排版图片的列切分	未做（单栏优先）	依据版面检测切列
长词跨行截断（PDF 表格）	少数长词（如 <code>comprehension</code> ）解析不到	单元格碎片拼接（需防误粘）
听力训练	未覆盖 （能力边界：覆盖除听力外各环节）	未列入本期

10. 附录

10.1 关键常量

```
PORT = 8804                ENGINE_PORT = 8080
MAX = 2000                 （单块字符阈值）
KEEP_LINE = {小学:A1, 初中:A1, 高一:A2, 高二:B1, 高三:B1, 大学:B2}
LVL_N      = {A1:1, A2:2, B1:3, B2:4, C1:5, C2:6}
BUILTIN_BOOKS = cefr / cet4 / cet6      （+ zk/gk 启动时自动发现）
```

10.2 server.js 函数清单（56）

索引与词书	buildBookIndex loadCet readSettings writeSettings slugId inferKind registerBook loadAllBooks primaryIndex bookBrief parseTextWordList importBookFromPdf importBook
分层引擎	scanList scanLeveled scanBook scanCefr scanCet passKeep buildCandidates annotate
提炼	buildSystemPrompt llamaChat ollamaChat extractFromText splitText parseModelJson extractData fillContextMeanings makeDistractors
输入与图像	isGarbled ocrImage findPy saveMode ocrKickIdle ensureOcr prepImage engineAlive dedupeLines removeJunkLines visionReadFiles cleanupVisionText ocrFast visionTopPassage cropTop topStripRecovery cropBand badishLine countLeadBad countTailBad headTailBad v4Supplement

	visionStripSupplement refineHeadTail
判卷/工具	splitSent findSent

本设计文档随代码演进维护；实现与本文不一致时以代码为准。